03-softmax

June 14, 2020

1 Atividade 03: Classificador Softmax

Complete e entregue toda essa atividade (incluindo suas saídas e qualquer código adicional que você desenvolva) juntamente com a submissão de seu trabalho prático. Maiores detalhes podem ser vistos na página da disciplina.

Esta atividade é análoga a feita anteriormente sobre SVM. Você irá:

- implementar uma **função de perda** (**loss function**) de forma completamente paralela para o classificador Softmax
- implementar a expressão para seu gradiente analítico de forma completamente paralela
- verificar sua implementação utilizando gradiente numérico
- usar um conjunto de validação para ajustar a taxa de aprendizado e regularização
- otimizar a função de perda com SGD
- visualizar os pesos finais que foram obtidos

```
In [7]: def get_CIFAR10_data(num_training=49000, num_validation=1000, num_test=1000, num_dev=500
            Carrega CIFAR-10 dataset a partit do disco e realiza preprocessamento para preparar
            os dados para o classificador linear. Estes são os mesmos passos usados para o model
            SVM, porém condensado em uma única função.
            # Carregga os dados CIFAR-10 brutos
            cifar10_dir = 'dl/datasets/cifar-10-batches-py'
            X_train, y_train, X_test, y_test = load_CIFAR10(cifar10_dir)
            # Subdivide os dados em conjuntos
            mask = list(range(num_training, num_training + num_validation))
            X_val = X_train[mask]
            y_val = y_train[mask]
            mask = list(range(num_training))
            X_train = X_train[mask]
            y_train = y_train[mask]
            mask = list(range(num_test))
            X_{\text{test}} = X_{\text{test}}[mask]
            y_test = y_test[mask]
            mask = np.random.choice(num_training, num_dev, replace=False)
            X_dev = X_train[mask]
            y_dev = y_train[mask]
            # Preprocessamento: redimensiona as imagens de matrizes para vetores
            X_train = np.reshape(X_train, (X_train.shape[0], -1))
            X_val = np.reshape(X_val, (X_val.shape[0], -1))
            X_test = np.reshape(X_test, (X_test.shape[0], -1))
            X_dev = np.reshape(X_dev, (X_dev.shape[0], -1))
            # Normaliza os dados: subtrai a imagem média
            mean_image = np.mean(X_train, axis = 0)
            X_train -= mean_image
            X_val -= mean_image
            X_test -= mean_image
            X_dev -= mean_image
            # Acrescenta uma dimensão (viés/bias) e transforma em colunas
            X_train = np.hstack([X_train, np.ones((X_train.shape[0], 1))])
            X_val = np.hstack([X_val, np.ones((X_val.shape[0], 1))])
            X_test = np.hstack([X_test, np.ones((X_test.shape[0], 1))])
            X_dev = np.hstack([X_dev, np.ones((X_dev.shape[0], 1))])
            return X_train, y_train, X_val, y_val, X_test, y_test, X_dev, y_dev
        # Usar a função definida acmina para obter os dados.
        X_train, y_train, X_val, y_val, X_test, y_test, X_dev, y_dev = get_CIFAR10_data()
```

```
print('Train data shape: ', X_train.shape)
        print('Train labels shape: ', y_train.shape)
        print('Validation data shape: ', X_val.shape)
        print('Validation labels shape: ', y_val.shape)
        print('Test data shape: ', X_test.shape)
        print('Test labels shape: ', y_test.shape)
        print('dev data shape: ', X_dev.shape)
        print('dev labels shape: ', y_dev.shape)
        print('Okay!')
Train data shape: (49000, 3073)
Train labels shape: (49000,)
Validation data shape: (1000, 3073)
Validation labels shape: (1000,)
Test data shape: (1000, 3073)
Test labels shape: (1000,)
dev data shape: (500, 3073)
dev labels shape: (500,)
Okay!
```

1.1 Classificador Softmax

Seu código para está seção será todo escrito dentro do arquivo dl/classifiers/softmax.py.

1.2 **Pergunta 01:**

Por que se deve esperar que a perda calculada seja próxima de $-\log(0.1)$? Explique brevemente.

Sua Resposta: *Pois como o W é aleatório, e sua probabilidade é de 1/10, o valor é 10% (0.1)*

```
In [9]: # Complete a implementação da função softmax_loss_naive, acrescentando uma
        # versão (ingênua) de cálculo do gradiente que utilize laços aninhados.
        loss, grad = softmax_loss_naive(W, X_dev, y_dev, 0.0)
        # Como foi feito para o SVM, use a estimativa numérica do gradiente como
        # ferramenta de verificação e depuração.
        # O valor do gradiente numérico deve ser próximo do obtido analiticamente.
        from dl.gradient_check import grad_check_sparse
        f = lambda w: softmax_loss_naive(w, X_dev, y_dev, 0.0)[0]
        grad_numerical = grad_check_sparse(f, W, grad, 10)
        # Similar ao SVM, faça outra verificação utilização um valor de regularização não nulo
        loss, grad = softmax_loss_naive(W, X_dev, y_dev, 5e1)
        f = lambda w: softmax_loss_naive(w, X_dev, y_dev, 5e1)[0]
        grad_numerical = grad_check_sparse(f, W, grad, 10)
        print('Okay!')
numerical: 0.506040 analytic: 0.506040, relative error: 1.872356e-09
numerical: -4.855755 analytic: -4.855756, relative error: 1.473418e-08
numerical: -0.600113 analytic: -0.600113, relative error: 5.381051e-09
numerical: -0.871733 analytic: -0.871733, relative error: 1.842650e-08
numerical: 1.909631 analytic: 1.909631, relative error: 2.660218e-08
numerical: -2.038483 analytic: -2.038483, relative error: 4.373347e-08
numerical: -1.360065 analytic: -1.360065, relative error: 6.311857e-08
numerical: 3.023074 analytic: 3.023074, relative error: 1.310259e-08
numerical: -1.094234 analytic: -1.094234, relative error: 3.624755e-08
numerical: 1.155066 analytic: 1.155066, relative error: 3.672406e-08
numerical: -2.525703 analytic: -2.525703, relative error: 3.909059e-08
numerical: -1.235736 analytic: -1.235736, relative error: 2.113284e-08
numerical: 1.798328 analytic: 1.798327, relative error: 3.627317e-08
numerical: -1.620961 analytic: -1.620961, relative error: 9.297531e-10
numerical: 2.709871 analytic: 2.709871, relative error: 2.286845e-08
numerical: -0.078640 analytic: -0.078640, relative error: 1.417349e-07
numerical: 1.582100 analytic: 1.582100, relative error: 1.823098e-08
numerical: -2.555849 analytic: -2.555850, relative error: 6.215271e-09
numerical: 1.040267 analytic: 1.040267, relative error: 1.021206e-08
numerical: 1.449088 analytic: 1.449088, relative error: 5.103152e-08
Okay!
```

```
# você deve implementar uma versão vetorial/paralela na função softmax_loss_vectorized.

# Novamente, os valores devem coincidir porém a versão vetorial deve ser mais rápida.
tic = time.time()
```

In [10]: # Agora que se tem uma versão básica de para cálculo da função de perda e de seu gradie

```
loss_naive, grad_naive = softmax_loss_naive(W, X_dev, y_dev, 0.000005)
        toc = time.time()
        print('naive loss: %e computed in %fs' % (loss_naive, toc - tic))
        from dl.classifiers.softmax import softmax_loss_vectorized
        tic = time.time()
        loss_vectorized, grad_vectorized = softmax_loss_vectorized(W, X_dev, y_dev, 0.000005)
        toc = time.time()
        print('vectorized loss: %e computed in %fs' % (loss_vectorized, toc - tic))
        # Como para o SVM, utiliza-se a norma de Frobenius para comparar as duas versões
        # de gradiente.
        grad_difference = np.linalg.norm(grad_naive - grad_vectorized, ord='fro')
        print('Loss difference: %f' % np.abs(loss_naive - loss_vectorized))
        print('Gradient difference: %f' % grad_difference)
        print('Okay!')
naive loss: 2.319804e+00 computed in 0.158620s
vectorized loss: 2.319804e+00 computed in 0.003905s
Loss difference: 0.000000
Gradient difference: 0.000000
Okay!
In [13]: # Utilize o conjunto de validação para ajustar os hiperparâmetros (taxa de
        # aprendizado e regularização). Você deve experimentar diferentes intervalos
        # para ambos. Se você proceder corretamente deve ser capaz de obter uma acurácia
        # acima de 0.35 no conjunto de validação.
        from dl.classifiers import Softmax
        results = {}
        best_val = -1
        best_softmax = None
        learning_rates = [1e-8, 1e-7, 2e-7]
        regularization_strengths = [1e4, 2e4, 3e4, 4e4, 5e4, 6e4, 7e4, 8e4, 1e5]
        # TODO:
        # Escrever o código que escolhe os melhores hiperparâmetros usando o conjunto
        # de validação. Deve ser muito similar ao código feito para o SVM.
        # Além disso, deve-se armazenar a melhor acurácia de validação em best_val
                                                                                 #
        # e o objeto Softmax que obteve esse resultado em best_softmax.
        iters = 2000
        for lr in learning_rates:
            for rs in regularization_strengths:
```

```
softmax.train(X_train, y_train, learning_rate=lr, reg=rs, num_iters=iters)
                y_train_pred = softmax.predict(X_train)
                acc_train = np.mean(y_train == y_train_pred)
                y_val_pred = softmax.predict(X_val)
                acc_val = np.mean(y_val == y_val_pred)
                results[(lr, rs)] = (acc_train, acc_val)
                if best_val < acc_val:</pre>
                   best_val = acc_val
                    best_softmax = softmax
        FIM DE SEU CÓDIGO
        # Exibe os resultados.
        for lr, reg in sorted(results):
            train_accuracy, val_accuracy = results[(lr, reg)]
            print('lr %e reg %e train accuracy: %f val accuracy: %f' % (
                       lr, reg, train_accuracy, val_accuracy))
        print('best validation accuracy achieved during cross-validation: %f' % best_val)
        print('Okay!')
lr 1.000000e-08 reg 1.000000e+04 train accuracy: 0.187612 val accuracy: 0.178000
lr 1.000000e-08 reg 2.000000e+04 train accuracy: 0.180020 val accuracy: 0.185000
lr 1.000000e-08 reg 3.000000e+04 train accuracy: 0.187551 val accuracy: 0.210000
lr 1.000000e-08 reg 4.000000e+04 train accuracy: 0.190714 val accuracy: 0.170000
lr 1.000000e-08 reg 5.000000e+04 train accuracy: 0.192857 val accuracy: 0.187000
lr 1.000000e-08 reg 6.000000e+04 train accuracy: 0.210102 val accuracy: 0.185000
lr 1.000000e-08 reg 7.000000e+04 train accuracy: 0.217755 val accuracy: 0.228000
lr 1.000000e-08 reg 8.000000e+04 train accuracy: 0.213122 val accuracy: 0.220000
lr 1.000000e-08 reg 1.000000e+05 train accuracy: 0.255449 val accuracy: 0.274000
lr 1.000000e-07 reg 1.000000e+04 train accuracy: 0.355694 val accuracy: 0.392000
lr 1.000000e-07 reg 2.000000e+04 train accuracy: 0.359020 val accuracy: 0.373000
lr 1.000000e-07 reg 3.000000e+04 train accuracy: 0.347408 val accuracy: 0.358000
lr 1.000000e-07 reg 4.000000e+04 train accuracy: 0.336408 val accuracy: 0.342000
lr 1.000000e-07 reg 5.000000e+04 train accuracy: 0.332184 val accuracy: 0.347000
lr 1.000000e-07 reg 6.000000e+04 train accuracy: 0.319306 val accuracy: 0.332000
lr 1.000000e-07 reg 7.000000e+04 train accuracy: 0.322673 val accuracy: 0.331000
lr 1.000000e-07 reg 8.000000e+04 train accuracy: 0.311673 val accuracy: 0.331000
lr 1.000000e-07 reg 1.000000e+05 train accuracy: 0.300714 val accuracy: 0.318000
lr 2.000000e-07 reg 1.000000e+04 train accuracy: 0.374571 val accuracy: 0.392000
1r 2.000000e-07 reg 2.000000e+04 train accuracy: 0.355939 val accuracy: 0.376000
```

softmax = Softmax()

```
1r 2.000000e-07 reg 3.000000e+04 train accuracy: 0.348204 val accuracy: 0.362000
lr 2.000000e-07 reg 4.000000e+04 train accuracy: 0.327082 val accuracy: 0.345000
1r 2.000000e-07 reg 5.000000e+04 train accuracy: 0.332694 val accuracy: 0.350000
1r 2.000000e-07 reg 6.000000e+04 train accuracy: 0.320265 val accuracy: 0.322000
1r 2.000000e-07 reg 7.000000e+04 train accuracy: 0.313592 val accuracy: 0.328000
1r 2.000000e-07 reg 8.000000e+04 train accuracy: 0.310490 val accuracy: 0.335000
lr 2.000000e-07 reg 1.000000e+05 train accuracy: 0.317429 val accuracy: 0.329000
best validation accuracy achieved during cross-validation: 0.392000
Okay!
In [14]: # Avalia o melhor modelo Softmax no conjunto de teste
        y_test_pred = best_softmax.predict(X_test)
         test_accuracy = np.mean(y_test == y_test_pred)
         print('softmax on raw pixels final test set accuracy: "f' " (test_accuracy, ))
        print('Okay!')
softmax on raw pixels final test set accuracy: 0.354000
Okay!
In [16]: # Visualiza os pesos obtidos para cada classe.
        w = best_softmax.W[:-1,:] # remove o viés/bias
         w = w.reshape(32, 32, 3, 10)
         w_{\min}, w_{\max} = np.min(w), np.max(w)
         classes = ['plane', 'car', 'bird', 'cat', 'deer', 'dog', 'frog', 'horse', 'ship', 'truc'
         for i in range(10):
             plt.subplot(2, 5, i + 1)
             # Redimensiona os pesos para o intervalo entre 0 e 255
             wimg = 255.0 * (w[:, :, i].squeeze() - w_min) / (w_max - w_min)
             plt.imshow(wimg.astype('uint8'))
             plt.axis('off')
             plt.title(classes[i])
        print('Okay!')
Okay!
```



